

MAPPO 与 HAPPO 在 SMAC 上的复现实验

学号：待填写 姓名：待填写 邮箱：待填写

摘要： 本文基于 HARL 代码库和 SMAC 环境，复现 MAPPO 与 HAPPO 在 3s5z 和 8m_vs_9m 两个地图上的训练流程。当前工作已经完成环境安装、代码定位、四组 smoke test、四组 10000-step pilot、progress.txt 汇总和 win rate 绘图；单 seed 正式训练已启动，并同步到 3s5z MAPPO 的 560000-step checkpoint。由于完整长训练尚未结束，本文现阶段报告重点是复现流程、代码对应关系和阶段性验证结果。

1. 引言

星际争霸多智能体挑战（SMAC）提供了完全合作的多智能体微操任务，适合评估多智能体强化学习算法的协同决策能力。每个智能体只能观察局部信息并选择离散动作，但训练和评估关注的是团队是否能击败敌方单位。本作业关注 MAPPO 与 HAPPO 在 SMAC 上的训练、测试和分析流程。

2. 算法概述

MAPPO

MAPPO 可以理解为将单智能体 PPO 扩展到多智能体合作场景。每个智能体执行去中心化策略，训练阶段使用集中式信息估计价值函数，并通过 PPO clipped surrogate objective 限制策略更新幅度。相比从零设计复杂的 credit assignment 机制，MAPPO 的重点是把 PPO 中优势估计、策略比值裁剪、熵正则和集中式 critic 组合成稳定的 on-policy 多智能体训练流程。

HAPPO

HAPPO 在异质智能体场景下引入顺序策略更新。其核心思想是使用多智能体优势分解，并在更新当前智能体时通过 factor 修正前序智能体策略更新对联合策略概率比的影响。与 MAPPO 直接独立或共享更新 actor 不同，HAPPO 在一个 update 内按智能体顺序逐个更新策略，并把已经更新过的智能体对联合策略概率的影响累积到后续智能体的 surrogate objective 中。

3. HARL 代码对应

概念	HARL 位置	说明
HAPPO actor	happo.py:10	定义 HAPPO actor 更新逻辑。
MAPPO actor	mappo.py:10	定义 MAPPO actor 更新逻辑。

概念	HARL 位置	说明
PPO clip	happo.py:73	在 importance ratio 上做 clip。
HAPPO factor	happo.py:79	actor loss 乘以前序策略更新 factor。
factor 更新	on_policy_ha_runner.py:115	用新旧动作概率比更新 factor。
GAE	on_policy_critic_buffer_ep.py:97	从后往前递归 return。
win rate	smac_logger.py:166	写入 progress.txt 第三列。

HARL 中 HAPPO 与 MAPPO 的核心差别主要体现在 runner 和 actor update 两层。HAPPO runner 初始化 factor 为 1，按固定或随机顺序遍历智能体；每个智能体更新前把当前 factor 写入 actor buffer，更新后用新旧策略动作概率比更新 factor。MAPPO actor 同样计算 PPO clipped surrogate，但没有 HAPPO 的顺序 factor。

4. 环境配置

实验在本机 Linux 环境中进行。硬件为 NVIDIA GeForce RTX 5090，显存约 32GB。软件环境使用 Conda 创建 harl_hw3，Python 版本为 3.10，PyTorch 为 2.12.0+cu130，CUDA 可用。HARL 克隆到 external/HARL，commit 为 b1af98b0dbab72a2eee9d160751cd09aedbb8ce2。

SMAC 依赖使用 oxwhirl 的 StarCraft Multi-Agent Challenge 包，而不是 PyPI 上同名的算法配置优化库。StarCraft II Linux 4.10 安装到 /home/yongqian/StarCraftII，SMAC maps 已复制到 Maps/SMAC_Maps，共 23 张。验证命令 python -m smac.bin.map_list 能列出目标地图，python -m smac.examples.random_agents 能成功启动 SC2。

实际安装中还处理了 PyTorch 2.12 与 NumPy 1.23 的兼容问题：环境改用 NumPy 2，并通过 `scripts/patch_harl_numpy2.py` 把 HARL 中旧的 `np.int/np.bool` 写法替换为 Python 内置类型。

5. 复现流程

复现过程被拆分为环境安装、命令生成、短训练验证、日志汇总和绘图五个阶段。环境安装由 `scripts/setup_env.sh` 管理，目标是避免在 base Python 3.13 环境中混装 PyTorch、SMAC 和 HARL。脚本会创建 `harl_hw3` 环境、安装 HARL editable package、安装 `oxwhirl` SMAC、安装 `gym 0.21`，并执行导入检查。

训练命令由 `scripts/run_smac_experiments.sh` 管理。该脚本提供四种模式：`dry-run` 打印四组实验命令；`smoke` 把训练步数、并行环境数和评估 episode 降到很小，用于确认 SC2 可以启动且 HARL 可以写出日志；`pilot` 默认使用 10000 environment steps，用于正式训练前的短跑检查；`full` 保留 tuned config 的正式训练设置。这样可以先快速验证链路，再把同一套命令用于长时间正式训练。

日志处理由 `scripts/collect_progress.py` 和 `scripts/plot_win_rate.py` 完成。HARL 的 SMAC logger 在 evaluation 阶段将 `total_num_steps`、平均 episode reward 和 `eval_win_rate` 写入 `progress.txt`。收集脚本会扫描 HARL 输出目录和本作业保存的 `raw` 目录，按地图、算法、实验名、run 和 step 去重，再输出统一 CSV。绘图脚本读取同一批数据，按地图生成 MAPPO/HAPPO 曲线。

6. 实验设置

实验矩阵包括 MAPPO 与 HAPPO 在 3s5z 和 8m_vs_9m 上的训练。HAPPO 使用 HARL 官方 tuned config；由于当前 HARL commit 缺少这两个地图的 MAPPO tuned config，MAPPO 暂基于同地图 HAPPO tuned config 生成，并切换为 MAPPO 的参数共享和固定顺序设置。当前脚本已经覆盖 `dry-run`、`smoke`、`pilot` 和 `full` 四种运行模式。

算法	地图	配置来源
MAPPO	3s5z	generated config
HAPPO	3s5z	HARL tuned config
MAPPO	8m_vs_9m	generated config
HAPPO	8m_vs_9m	HARL tuned config

7. 结果与分析


目前已完成四组 1000 environment steps 的 smoke test，用于验证环境、训练脚本、日志收集和绘图流程。随后又完成了四组 10000-step pilot run，覆盖 MAPPO/HAPPO 与 3s5z/8m_vs_9m 的完整实验矩阵。2026-05-31 已在 tmux 中启动单 seed full tuned config，并同步到 3s5z MAPPO 的 7 个 evaluation，当前最新 step 为 560000。由于正式训练仍在运行，这些结果只能作为流程、短跑和早期 full checkpoint 证据，不能作为最终算法性能结论。

Pilot run 最后一次 evaluation 结果


地图	算法	Step	Eval reward / win rate
3s5z	HAPPO	9600	4.0629 / 0.0
3s5z	MAPPO	9600	7.6954 / 0.0
8m_vs_9m	HAPPO	9600	5.0072 / 0.0
8m_vs_9m	MAPPO	9600	7.5108 / 0.0

Full run 阶段性 checkpoint

地图	算法	Step	Eval reward / win rate
3s5z	MAPPO	560000	14.5985 / 0.225



3s5z smoke/pilot 与阶段性 full eval win rate.



8m_vs_9m smoke/pilot eval win rate; 该地图 full run 尚未到达第一轮评估。

正式训练完成后，应使用相同脚本重新生成曲线，并重点比较 MAPPO 与 HAPPO 的收敛速度、最终胜率和训练稳定性。对于当前结果，主要结论是训练、评估、日志、汇总和绘图链路已经打通；四组 pilot 均能稳定运行到 10000-step 量级；full 模式已成功进入第一组

MAPPO/3s5z 训练并写出 evaluation, 早期 win rate 已从 0 增至 0.225。但 560000 步仍远低于 HARL tuned config 中的 2000 万步, 不能用于判断 MAPPO 与 HAPPO 的最终性能。

8. 局限性

当前结果的主要局限是训练步数不足。SMAC 任务需要大量交互样本才能学习到稳定微操策略, 尤其是 8m_vs_9m 这种非对称地图, 随机策略和短训练几乎不可能得到胜利。因此当前 eval win rate 为 0 并不说明算法无效, 只说明当前运行覆盖了流程验证、四组短跑检查和早期 full checkpoint。正式报告中应补充完整训练曲线, 或明确说明计算预算不足导致未完成正式复现。

9. 结论

当前阶段已经完成环境配置、代码阅读定位、四组 smoke test、四组 10000-step pilot run、单 seed 正式训练启动和自动绘图。后续正式训练完成后, 应把阶段性曲线替换为完整训练曲线, 并基于 win rate 的收敛速度、最终胜率和波动情况讨论 MAPPO 与 HAPPO 的差异。若计算资源不足, 报告需要明确说明只完成了流程验证和阶段性 full checkpoint, 并把正式训练命令、配置和资源瓶颈作为复现实验记录的一部分。

参考文献

- [1] Yu, C. et al. The Surprising Effectiveness of PPO in Cooperative Multi-Agent Games. NeurIPS, 2022.
- [2] Zhong, Y. et al. Heterogeneous-Agent Reinforcement Learning. JMLR, 2024.
- [3] Samvelyan, M. et al. The StarCraft Multi-Agent Challenge. arXiv:1902.04043, 2019.